

Крутой конспект (точно не сделанный
через моего крутого бота)

1. Переменные в анализе данных

— Статистическая переменная —
измеряемая характеристика, меняющаяся
между наблюдениями.

— Типы переменных:

— Категориальные (качественные)

— Пример: пол, штат, группа крови

— В pandas: тип Categorical

— Непрерывные (количественные)

— Пример: возраст, доход, температура

— В pandas: int, float

2. Временные ряды

— Упорядоченные по времени данные.

— Часто используются в финансах (цены
акций, курсы валют).

— Pandas предоставляет мощные
инструменты

— Преобразование временных меток

— Ресемплирование

— Скользящие окна

3. Основы анализа данных

— Качественный анализ — неметрические
признаки ("мягкость", "цвет").

— Количественный анализ — числовые
данные.

— Подходы:

— Одномерный (univariate): анализ одной
переменной

— Гистограммы, среднее, медиана

— Многомерный (multivariate): связи

меню переменными

- Корреляция, регрессия, кластеризация

4. Статистические понятия

- Описательная статистика:

- Среднее, медиана, мода

- Дисперсия, стандартное отклонение

- Форма распределения (нормальное, скошенное и т.д.)

- Индуктивная статистика (выводы о генеральной совокупности):

- t-тест, ANOVA, хи-квадрат

- Реализуется не в pandas, а в SciPy / StatsModels

5. Корреляция и регрессия

- Корреляция - мера линейной связи

меню переменными.

- В pandas: `df.corr()`

- Регрессия - моделирование зависимости ($y = f(x_1, x_2, \dots)$)

- Перенесена в библиотеку StatsModels

6. Стохастические и байесовские модели

- Стохастические модели учитывают случайность (например, Монте-Карло).

- Байесовская статистика: обновление вероятностей через теорему Байеса.

- Для этого используются специализированные библиотеки:

- PyMC - байесовское моделирование

- StatsModels - классическая и провозимая статистика

7. Экосистема python для анализа данных
- Numpy - базовые массивы, математика
 - Pandas - структурирование, очистка, описание данных
 - SciPy - научные вычисления, статистические тесты
 - StatsModels - регрессии, временные ряды, выводная статистика
 - Scikit-learn - машинное обучение (классификация, кластеры)
 - PyMC - байесовские модели
 - Matplotlib - базовая визуализация
 - Seaborn - красивые статистические графики

Вывод:

- Pandas - это инструмент для подготовки и описательного анализа данных.
- Для сложной статистики, ML и визуализации он работает в связке с другими библиотеками.